

Potato LLM

W2

내 감자에 뭘 올릴 것인가

2026.7.29

최세영
황재성
김태한
강민석

오늘의 질문

지난주 질문에서 한 걸음 더

~~감자 컴퓨터에서 AI 에이전트가 돌아갈까?~~

그럼, 내 감자에 뭘 올릴 건데?

01

뭘 올리지

SLM은 어떻게 작아졌나

02

→

어떻게 올리지

실행기를 고른다

03

→

어떤 걸 올리지

오늘의 진짜 주제

지금 오픈소스 LLM은 이 정도 크기다

받을 수 있는 것과 돌릴 수 있는 것은 다르다

Kimi K3  2.8T 2026.7.26 공개 · 역대 최대

GLM-5.2  753B

Qwen3-Coder  480B

----- 감자 커트라인 · 램 16GB 언저리 -----

Llama 3.2 3B  3B 4비트로 약 2GB — 노트북에서 돈다

Gemma 3n E2B  2B 약 1.5GB — 폰에서도

기준은 파라미터 수가 아니라 **메모리**입니다 — 내 램에 들어가느냐.

4비트로 눌러도 3B는 약 2GB, 8B급은 약 5GB. 노트북 램이나 무료 Colab GPU가 16GB 언저리라 그쯤이 한계선입니다.

Alpaca — 오픈소스 파인튜닝이 열린 날


2023.03 · 라마가 풀리고 한 달 뒤

라마 7B를 **600달러 미만**으로 튜닝했습니다.

"우리도 만들 수 있다"가
여기서 시작됩니다.

- 2023년 초, 메타가 라마를 공개 — 쓸 만한 가중치가 처음 밖으로
- 한 달 뒤 스탠퍼드가 그 라마 7B를 튜닝해 **알파카**를 만들
- 그전까진 "저런 건 큰 회사만 만드는 것"이었다
- **!** 다만 모델을 통째로 다시 학습시킨 것 — A100 여러 장이 필요했다

2023.03



그래서 곧바로 나온 질문 —
더 싸게 할 순 없나?

LoRA — 여백에 메모지를 붙인다

본체는 얼리고 작은 메모지만 학습

ΔW 를 통째로 두지 않고


얇은 행렬 두 개의 곱으로 쪼갭니다.

학습할 파라미터가 1% 미만으로.

- 파인튜닝 = 가중치 W 에 변화량 ΔW 를 더하는 것. 그런데 ΔW 가 원본과 같은 크기
- LoRA의 관찰 — 실제 필요한 변화량은 그렇게 복잡하지 않다
- 그래서 얇은 행렬 두 개로 쪼갬다. 가운데 차원은 8~16. 원본 W 는 얼려둔다
- QLoRA — 본체를 4비트로 눌러 올리고 메모지만 학습 → GPU 한 장으로

W3에서 다룹니다

2023.03



본문은 그대로 · 메모지만 교체


Llama 3.2 — 가지를 쳐낸다

Pruning

8B짜리에서 **덜 중요한 가지를 쳐내서**
1B, 3B를 만들었습니다.

- 메타 공식 — 1B·3B는 8B에서 구조적 가지치기로 만든 것
- 자르면 성능이 떨어진다고 → 큰 모델(8B·70B)의 답을 보고 복원
- 소형 모델 중 가장 널리 쓰이는 축

W5에서 직접 해봅니다



DeepSeek-R1-Distill — 선생과 학생


Knowledge Distillation

이름에 그대로 써 있어요. **Distill**, 증류.
거대한 R1이 푼 풀이 과정 80만 개를
작은 Qwen에게 그대로 베끼게 한 겁니다.

- 큰 모델이 선생, 작은 모델이 학생
- R1-Distill은 선생이 푼 풀이를 통째로 베껴 학습하는 방식 — **671B** → **7B**, 거의 100분의 1
- Gemma는 한 걸음 더 — 선생의 확률 분포까지 학습 (27B → 2B-9B)
- Ollama에서 가장 많이 받는 모델 중 하나

W5에서 직접 해봅니다

2025.01



DeepSeek-R1-Distill-Qwen-7B

Qwen — 소수점을 반올림한다

Quantization · 오늘 실습에서 바로 만난다

이따 실습에서 **ollama pull** 하실 겁니다.
그때 받는 게 **원본이 아니에요.**
이미 4비트로 눌린 파일입니다.

- 가중치 소수점 정밀도를 낮춰 용량·속도를 줄이는 것
- 16비트 → 4비트면 **파일이 1/4**, 속도는 대략 **2배**
- Ollama가 기본으로 주는 게 Q4_K_M — 대부분 모르고 쓴다
- "그럼 성능은 얼마나 떨어지나?" → **W4**에서 직접 잡니다

W4에서 직접 해봅니다

3.141592653589




3.14

```
ollama pull qwen2.5:3b
```

받는 순간 이미 **Q4_K_M**

파일만으론 안 돌아간다

02 · 어떻게 올리지



모델을 받았다고 돌아가지 않습니다. **틀어줄 재생기**가 있어야 해요.

mp3 파일이 있어도 플레이어가 없으면 못 듣죠. 모델 파일도 똑같습니다.

q4 기본 4비트	k 중요한 레이어는 6비트 로 남긴다	m S · M · L 중 가운데
---------------------	---------------------------------------	------------------------------------

실행기 3종과 선택

왜 셋으로 갈렸나 — 누구를 상대하느냐

	llama.cpp	Ollama	vLLM
성격	GGUF 원조 · 진짜 엔진	llama.cpp를 감싼 것	여럿이 쓰는 서버용
장점	CPU에서도 돌 출력 형식 강제 가능 옵션이 전부 열림	설치 한 번, pull 한 줄 모델 관리 자동 표준 도구 호출 지원	요청을 계속 묶어 GPU를 놀리지 않음
단점	빌드·옵션 진입장벽 서버를 직접 띄워야	세밀한 제어 어려움 정해진 틀 안에서만	GPU 필수 맥에선 빌드 실패
이럴 때	옵션을 손봐야 할 때 (W6에서 다시)	처음 · 로컬 실험	서버 서비스 (RunPod 심화)

셋 다 같은 모델 파일을 돌린다. 다른 건 성능이 아니라 **쉬운가 · 손댈 수 있는가 · 몇 명을 상대하는가**.

* 같은 파일도 실행기가 대화 형식을 다르게 채워 결과가 조금씩 달라진다 — W6에서 다시 만납니다

리더보드를 보면 되지 않나

03 · 어떤 걸 올리지

Model ↕	Features ↳		Intelligence ↳		Price ↳	Speed ↳	Latency ↳	End-to-End Response Time ↳	Further Analysis
	Context Window ↕	Creator ↕	Artificial Analysis Intelligence Index ↓		Cost per Task USD ↕	Median Tokens/s ↕	Latency First Chunk (s) ↕	Total Response (s) ↕	
Claude Opus 5 (max) ♀	1M	AI Anthropic	61		\$2.03	60	60.58	68.86	Model ↗ Providers ↗
Claude Opus 5 (xhigh) ♀	1M	AI Anthropic	60		\$1.56	55	42.33	51.49	Model ↗ Providers ↗
Claude Fable 5 (with fallback) ♀	1M	AI Anthropic	60		\$2.75	74	149.05	155.81	Model ↗ Providers ↗
GPT-5.6 Sol (max) ♀	1M	OpenAI	59		\$1.54	73	143.85	150.69	Model ↗ Providers ↗
Claude Opus 5 (high) ♀	1M	AI Anthropic	59		\$1.06	55	16.08	25.12	Model ↗ Providers ↗
GPT-5.6 Sol (xhigh) ♀	1M	OpenAI	58		\$0.94	71	33.92	40.97	Model ↗ Providers ↗
Kimi K3 ♀	1.05M	K Kimi	57		\$0.72	33	4.66	80.74	Model ↗ Providers ↗

출처 — Artificial Analysis, LLM Leaderboard (2026.7 캡처)

모델 고를 때 보통 이걸 봅니다. 점수 높은 걸 고르면 되잖아요. 맞나요?

벤치마크는 이런 걸 묻는다

그런데 내 업무는 이런 걸 요구한다

공개 벤치마크가 내는 문제

MMLU

"다음 중 옳은 것은? ① ② ③ ④"

GSM8K

"철수가 사과 5개를 샀는데..."

HumanEval

함수 하나 완성하기

정답이 하나, 채점이 쉽다

내 업무가 요구하는 것

회계

"지난달 미수금을 엑셀에서 뽑아 김부장님께 메일"

계약

"이 PDF에서 만료일만 뽑아 캘린더에 등록"

협업

"회의록 읽고 액션 아이템을 지라 티켓으로"

도구를 순서대로 불러야 한다

리더보드는 일을 안 재는 게 아닙니다. 재는 일이 남의 일입니다.

오늘 딱 하나만 가져가신다면

점수가 아니라 내 업무를 기준으로 재야 한다

좋은 모델 ≠ 내게 좋은 모델. 내 업무로 재면 3B가 70B보다 나을 수 있습니다 — 내 일에 한해서.
이것이 세 번째 산출물 **Potato Bench**의 정체입니다.

문항 하나에 들어가는 3요소

①만 있으면 시험지가 아니라 그냥 질문이다

① 입력	"서울 날씨 섭씨로 알려줘"	시키는 말
② 기대 동작	<code>get_weather(city="Seoul")</code>	뭘 불러야 정답인가
③ 검증	<code>city == "seoul"</code> 인가?	자동으로 채점하는 법 — 가장 많이 빠뜨린다

자동으로 채점돼야 **100번이든 1000번이든** 잴 수 있습니다. 사람이 눈으로 보면 30명이 함께 못 씁니다.

함정 문항도 넣으세요 — 도구로 할 수 없는 걸 시켜서, 모델이 지어내는지 봅니다.

왜 하필 도구 호출로 재나

에이전트의 최소 단위




이 **한 칸**이 틀리면 나머지가 다 무너집니다.

- 말을 잘하는 것과 **정확한 형식으로 도구를 부르는** 것은 다른 능력
- 자연어는 여러 표현이 다 맞지만, 도구 호출은 **한 글자만 틀려도 실패**
- 그래서 작은 모델의 실력 차이가 여기서 가장 선명하게 드러난다

모으면 벤치마크가 된다

혼자 만들면 내 시험지, 모으면 벤치마크



30명 × 20문항

600문항

그게 우리가 만들 Potato Bench입니다.

실습 — 직접 돌려보고, 내 문항 만들기

코드 짜실 필요 없습니다

1

파일 받아
Colab에 업로드

2

위에서부터
실행 버튼

3

마지막에
내 문항 추가


안 되면 디스코드에 화면을 그대로 캡처해서 올려주세요.

최소 코스 준비(0장) → 모델 선택 → 시험지 → 시험 실행

확장 내 업무 문항 만들기 → 실패 유형 분류

다음 주 — Pi 에이전트 만들기

W3 · 8월 5일



오늘 시험지를 만들었으니, 다음 주엔 **그 시험을 볼 놈**을 만듭니다.

해보시길
내 업무 문항 한두 개 적어보기